6/27 Discussion 速度の改善と新しい問題

TR24006 小林 亮太(中部大学工学部ロボット理工学科 藤吉研究室)

http://mprg.jp



はじめに



- 処理時間の問題
 - 対処方法
 - 追加の調査
- ・新たな問題 ~意図しない再起動~

• 実験進捗

処理時間の問題が対処方法



- Dataparallelが原因の可能性
 - マスターGPU以外のプロセスが残留
 - 最後に明示的に解放することが必要

• 最後にCPUに変えることでDPを解除

```
model = MyModel()
dp_model = torch.nn.DataParallel(model)
# 訓練やテストを実行
...
# DataParallelを解除し、モデルをCPUに移動
dp_model = dp_model.module.cpu()
```

処理時間の問題 調査結果



- 最後にCPUに変えることでDPを解除
- Line_profilerを用いて処理時間を計測

• 処理時間は短縮が確認されない結果

- 問題がかなり根深い可能性
 - 調査に割くリソースを制限
 - 実験に注力

処理時間の問題 追加の調査



- TrainOneBatch()関数をより詳細に調査
 - 関数内の各処理の時間を計測

• 条件は前回と同様

・実験が終わり次第調査

新たな問題~意図しない再起動~



- 意図していないタイミングで勝手にサーバーが再起動
 - 25日の発生を皮切りに連続して発生

再起動

- 学習開始後、1時間程度で発生する傾向

kobayashi@DLBox-114-21:/data2/kobayashi/MCN/model_me/TEST\$ last kobavash pts/0 192.168.112.170 Wed Jun 26 20:50 still logged in still running reboot system boot 5.19.0-32-generi Wed Jun 26 14:16 kobayash pts/10 192.168.112.170 Wed Jun 26 13:39 - 13:41 (00:01) 192.168.112.170 Wed Jun 26 12:16 - 12:35 (00:19) kobayash pts/10 kobayash pts/9 Tue Jun 25 13:58 - crash (1+00:17) kobayash pts/8 192.168.112.173 Tue Jun 25 13:55 - crash (1+00:21) kobayash pts/3 Tue Jun 25 13:49 - crash (1+00:27) 192.168.112.173 意図しない kobayash pts/2 192.168.112.173 Tue Jun 25 13:49 - crash (1+00:27) kobayash pts/1 192.168.112.173 Tue Jun 25 13:48 - crash (1+00:27) kobavash pts/0 192.168.112.173 Tue Jun 25 13:48 - crash (1+00:28) reboot 5.19.0-32-generi Tue Jun 25 12:49 still running system boot kobavash bts/4 192.168.112.171 | Tue Jun 25 10:34 - 10:42 (00:08) system boot 5.19.0-32-generi Tue Jun 25 10:28 reboot kopavash bts/0 5.19.0-32-generi Tue Jun 25 05:39 - 10:26 reboot system boot (04:47) 192.168.112.170 Sun Jun 23 21:40 - 21:40 (00:00) kobayash pts/9 kobayash pts/9 192.168.112.170 Sun Jun 23 09:30 - 09:31 (00:00)

意図した 再起動

新たな問題 ~意図しない再起動~



- 電力不足が原因の可能性
 - 周りのサーバーのパーツの変更
 - ログをほとんど残さずに突然シャットダウン
- 先週の停電による影響の可能性
 - 停電以前には発生なし
- •調査中
 - メモリ関連を調査予定
- 再び実験が停止
 - MTGまでに結果の報告が不可
 - 予定していた調査やDataloaderの改良を遅延

実験進捗



- AT_V, AV_T, VT_Aの3つのパターンで実験中
- AV_Tは完了
- AT_Vを完了
- VT_Aは未完了
 - 一段階目は完了 二段階目は中断中

おわりに



・実験:中断中 卒論時の実験の続き

• 再起動問題 : 迅速な解決を目指す

- ・ 今後の予定:
 - 実験の完了
 - 実験の完了後
 - Tarファイル作成を実行
 - 速度低下問題の追加調査
 - 実験の結果をまとめる

Dataloaderの改良



- 現在,np.loadを使用してnpzファイルをロード
 - ファイル数の分だけ実行
- ランダムアクセスからシーケンシャルアクセスに変更
 - データ数が多い場合, Dataloaderの効率が向上
- シーケンシャルアクセスのライブラリ
 - WebDataset ←今回使用
 - TFRecord

WebDataset



• Pytorch用のI/Oシステムライブラリ

- 大規模データセットへの効率的なアクセスが可能
 - シーケンシャルアクセスによる高速なディスクI/Oを実現
 - 数ペタバイト規模のデータセットにも対応
- データセットからシャードと呼ばれる複数のtarファイルを作成
 - tarファイルを頭から読むことでシーケンシャルアクセスを実現
 - tarファイル作成時にシャッフル



- tarファイル(シャード)の作成
 - tarファイル:圧縮機能ではなく,複数のファイルを1つにまとめるアーカイブ機能
 - 容量は据置 → データの置き場の問題が再発
 - 置き場の確保できるビデオデータのtarファイルのみ作成

- tarファイルの読み込み
 - 従来:ビデオIDリストのtxtファイルを参照しパスを補完 → パスからnp.loadでロード
 - ファイルの回数分繰り返し → ディスクへの多量のランダムアクセスが発生
 - 変更:まとめられた少数のtarファイルを参照して、各ファイルを上から順にロード
 - 多量のランダムアクセスを解消



- tarファイル(シャード)の作成
 - tarファイル:圧縮機能ではなく, 複数のファイルを1つにまとめるアーカイブ機能
 - 容量は据置 → データの置き場の問題が再発
 - 置き場の確保できるビデオデータのtarファイルのみ作成

- tarファイルの読み込み
 - 従来:ビデオIDリストのtxtファイルを参照しパスを補完 → パスからnp.loadでロード
 - ファイルの回数分繰り返し → ディスクへの多量のランダムアクセスが発生
 - 変更:まとめられた少数のtarファイルを参照して、各ファイルを上から順にロード
 - 多量のランダムアクセスを解消



- tarファイル(シャード)の作成
 - tarファイル:圧縮機能ではなく,複数のファイルを1つにまとめるアーカイブ機能
 - 容量は据置 → データの置き場の問題が再発
 - 置き場の確保できるビデオデータのtarファイルのみ作成

- tarファイル作成用コードは完成
 - 実験完了後に実行予定



- tarファイルの作成
 - tarファイル:圧縮機能ではなく,複数のファイルを1つにまとめるアーカイブ機能
 - 容量は据置 → データの置き場の問題が再発
 - 置き場の確保できるビデオデータのtarファイルのみ作成

- tarファイルの読み込み
 - 従来:ビデオIDリストのtxtファイルを参照しパスを補完 → パスからnp.loadでロード
 - ファイルの回数分繰り返し → ディスクへの多量のランダムアクセスが発生
 - 変更:まとめられた少数のtarファイルを参照して、各ファイルを上から順にロード
 - 多量のランダムアクセスを解消
 - 現在, 作成中

サーバーごとのスペック



• 170.2

- スレッド数 :32

- メモリ : 252GB

- 動作周波数 : 3.1GHz

• 114.21

- スレッド数 :64

- メモリ : 377GB

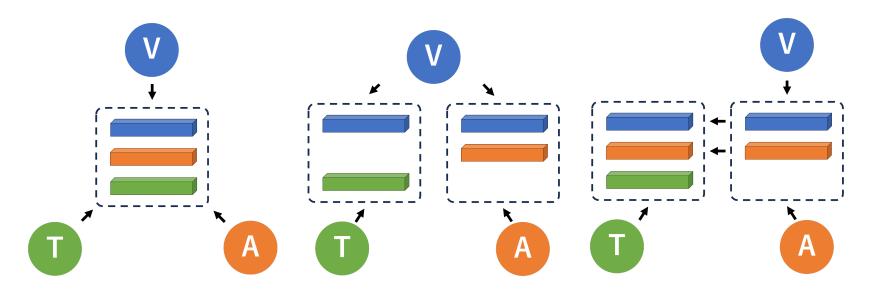
- 動作周波数 : 2.8GHz

• スレッド数,メモリ量では引越し先サーバーの方が優位

研究テーマ



- 3モーダルのマルチモーダル自己教師あり学習
 - ビデオ, オーディオ, テキスト
- テキストに比べビデオやオーディオにはノイズが多く存在
 - 各モーダルの組み合わせでノイズを抽出せずに学習ができる可能性
 - 近づけるモーダルの組み合わせによる学習効果への影響について調査



実験概要



- MCNを用いて近づけるモーダルの組み合わせ方による学習効果を調査
 - 3モーダルを二段階で学習する実験:V(ビデオ), A(オーディオ), T(テキスト)
 - AV_T:AとVで学習してからTを追加
 - VT A: VとTで学習してからAを追加
 - AT_V:AとTで学習してからVを追加
- 卒論時は低い精度
 - エポック数が不足
 - 追加の実験が必要

実験結果



• 実験中